# Автоматическая детекция фокально кортикальной дисплазии на разреженных данных

## О. С. Гребенькова

Московский физико-технический институт Физтех школа прикладной математики и информатики Кафедра интеллектуальных систем Научный руководителы д. ф. -м. н. Бурнаев Евгений Владимирович

21 июня 2023 г.

## Задача сегментации фокально-кортикальной дисплазии

#### Цель

Решается задача построения системы детекции и сегментации фокально кортикально дисплазии на трехмерных MPT изображениях головы.

#### Исследуемая проблема

Обработка и анализ полных MPT снимков требует огромных вычислительных ресурсов. Поэтому оптимизация модели для детекции  $\Phi$ КД является вычислительно сложной задачей.

#### Метод решения

Предлагаемый метод заключается в представлении МРТ данных в виде разреженного облака точек.

#### Постановка задачи

 $\bullet$  Дана выборка k объектов

$$\mathfrak{D} = \{\mathbf{x}_i, \mathbf{y}_i\}, \quad i = 1, \dots, k, \quad \mathbf{x}_i \in \mathbb{R}^{3 \times m}, \quad \mathbf{y}_i \in \mathbb{R}^{3 \times 1},$$

где  $\mathbf{x}_i$  — множество массивов, представляющих собой разные модальности трехмерных MPT снимков,  $\mathbf{y}_i$  — трехмерная разметка снимков.

2 Модель выбирается из класса нейронных сетей

$$\{\mathbf{f}_t: (\mathbf{X}, \mathbf{w}) \longrightarrow \hat{\mathbf{y}} | t \in \mathcal{T}\},$$

где  $\mathbf{w} \in \mathbb{W}$  — пространство параметров модели,  $\hat{\mathbf{y}} = \mathbf{f}(\mathbf{X}, \mathbf{w}) \in \mathbb{R}^{k \times 3 \times 1}$  — вероятность данного вокселя принадлежать классу ФКД,  $\mathbf{X} = \bigcup_{i=1}^k \mathbf{x}_i$ ;

В базовом подходе используется следующая функция ошибки

$$\mathcal{L}_{BCE} = -\frac{1}{k} \sum_{i=1}^{k} (\mathbf{y}_i \log(p(\mathbf{y}_i)) + (1 - \mathbf{y}_i) \log(1 - p(\mathbf{y}_i))).$$

Решается задача оптимизации

$$\mathbf{w}^* = \arg\min_{\mathbf{w} \in \mathbb{W}} (\mathcal{L}(\mathbf{X}, (w))).$$

## Разреженное представление для заданной выборки

#### Облако точек

$$\mathbf{P}_i = \{(u_j, v_j, w_j, \mathbf{c}_j) | j \in [1, n]\} \in \mathbb{R}^{3 \times m}, \quad \mathbf{P} = \bigcup_{i=1}^k \mathbf{P}_i,$$

где  $u_j, v_j, w_j$  — трёхмерные координаты точки в оригинальном пространстве,  $\mathbf{c}_j \in \mathbb{R}^m$  — вектор признаков.

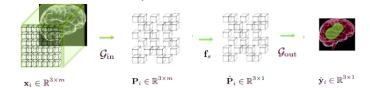
Рассмотрим два преобразования

$$\mathcal{G}_{\text{in}}: \mathbb{R}^{3 \times m} \longrightarrow \mathbb{R}^{3 \times m} \quad \mathcal{G}_{\text{out}}: \mathbb{R}^{3 \times 1} \longrightarrow \mathbb{R}^{3 \times 1},$$

переводящих  $\mathbf{X}$  в  $\mathbf{P}$  и  $\hat{\mathbf{P}}$  в  $\hat{\mathbf{y}}$  соответствено. Тогда итоговое преобразование  $\mathbf{f}_t$  можно представить в следующем виде

$$\mathbf{f}_t(\mathbf{X}, \mathbf{w}) = \mathcal{G}_{\mathrm{out}}(\mathbf{f}_s(\mathcal{G}_{\mathrm{in}}(\mathbf{X}), \mathbf{w})),$$

где  $\{\mathbf{f}_s: (\mathbf{P}, \mathbf{w}) \longrightarrow \hat{\mathbf{P}} | s \in \mathcal{S}; \mathcal{S} \subset \mathcal{T} \}.$ 



## Построение $\mathbf{f}_s$ : обобщенная свёртка

Пусть  $\mathbf{c}_{\mathbf{u}}^{\mathrm{in}} \in \mathbb{R}^{K_{\mathrm{in}}}$  — вектор параметров размерности  $K_{\mathrm{in}}$  поставленный в соответствии трехмерной координате  $\mathbf{u} \in \mathbb{R}^3$ . В этом случае ядро свертки:

$$\mathbf{W} \in \mathbb{R}^{9 \times K_{\text{out}} \times K_{\text{in}}}$$
.

Предлагается разбить это ядро на 9 матриц размерностей  $K_{\rm out} \times K_{\rm in}$ . Тогда классическая свертка может быть представлена следующей формулой

$$\mathbf{c}_{\mathbf{u}}^{\mathrm{out}} = \sum_{\mathbf{i} \in \mathcal{V}^3} \mathbf{W}_{\mathbf{i}} \mathbf{c}_{\mathbf{u}+\mathbf{i}}^{\mathrm{in}}; \quad \mathbf{u} \in \mathbb{R}^3,$$

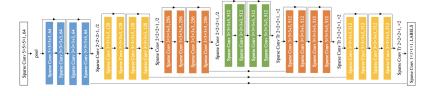
где  $\mathcal{V}^3$  смещения трехмерного куба (к примеру  $\mathcal{V}^1=\{-1,0,+1\}$ ) . Тогда обобщенная свертка может быть записана как

$$\mathbf{c}_{\mathbf{u}}^{\mathrm{out}} = \sum_{\mathbf{i} \in \mathcal{N}^{D}(\mathbf{u}, \mathcal{C}^{\mathrm{in}})} \mathbf{W}_{\mathbf{i}} \mathbf{c}_{\mathbf{u}+\mathbf{i}}^{\mathrm{in}}; \quad \mathbf{u} \in \mathcal{C}^{\mathrm{out}},$$

где  $\mathcal{N}^D(\mathbf{u}, \mathcal{C}^{\text{in}}) = \{\mathbf{i} | \mathbf{u} + \mathbf{i} \in \mathcal{C}^{\text{in}}, \mathbf{i} \in \mathcal{N}^D\}$  множество смещений, определяющих форму ядра,  $\mathcal{C}^{\text{in}}$  и  $\mathcal{C}^{\text{out}}$  определенные заранее входные и выходные координаты разреженных тензоров соответственно.

## Вычислительный эксперимент:модель и метрики

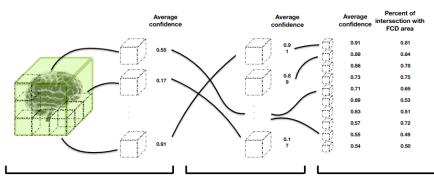
Вид используемой нейросети для эксперимента на MinkUNet14C:



#### Критерий качества модели

$$Dice = \frac{2TP}{2TP + FP + FN} \qquad Recall = \frac{TP}{TP + FN}$$

#### Вычислительный эксперимент: метрика



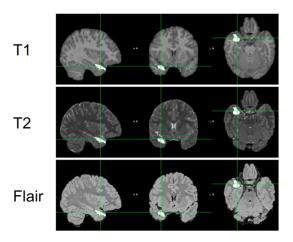
Prediction is divided into intersecting crops of defined size **C**. The average confidence is calculated for each such crop.

Crops are sorted with respect to the average confidence.

Intersection with FCD area is calculated for top **N** crops with respect to the average confidence.

### Вычислительный эксперимент на датасете

- 183 последовательности модальностей T1, T2, FLAIR и разметка.
- $\bullet$  10 статистических признаков по снимкам MPT (размытие, утолщение, кривизна и т.д.) и мозжечковые маски.
- В связи с малостью выборки, была проведена стратификация выборки. Для каждого эксперимента проводилась девяти фолдовая валидация.



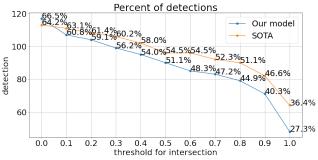
## Сравнение моделей для выборки из одной больницы



Данные	Функция потерь	Маска	Количество детектирований
T1w, T2w, FLAIR	BCE	нет	27
T1w, T2w, FLAIR + 10 стат. признаков	Focal	да	29
T1w, T2w, FLAIR + 10 стат. признаков	BCE	да	28
T1w, T2w, FLAIR	BCE	да	37

 $<sup>^1\</sup>mathrm{Multicenter}$  Validation of a Deep Learning Detection Algorithm for Focal Cortical Dysplasia, Gill S. et al.

# Сравнение моделей для всей выборки





- Mask of FCD
- Prediction of MinkUNet14C
- Prediction of SOTA model

## Выносится на защиту

- Исследовано использование разреженного представления для МРТ данных.
- Впервые предложен метод позволяющий использовать одновременно все модальности MPT совместно со статистическими признаками.
- ❸ Проведены эксперименты для различных моделей и выборок, подтверждающие работоспособность предложенного метода. Полученный подход позволяет добиться результатов сравнимых с state-of-the-art подходами.

#### Опубликованные работы

- Grebenkova O., Bakhteev O., Strijov V. Deep Learning Model Selection With Parametric Complexity Control, Proceedings of the 15th International Conference on Agents and Artificial Intelligence - Volume 2: ICAART, 2023
- Yakovlev K., Grebenkova O., Bakhteev O., Strijov V. Neural Architecture Search with Structure Complexity Control, Recent Trends in Analysis of Images, Social Networks and Texts, 2022